TP 1 : Analyse exploratoire de données

Dans ce TP, nous allons étudier le jeu de données *ACSIncome*. Le but de ce TP est d'effectuer une analyse exploratoire de données afin de mieux comprendre ce jeu de données, puis de prétraiter les données. Ce travail préparera le TP 2, où nous appliquerons et évaluerons différents algorithmes d'apprentissage supervisé. Ce TP se déroulera sur **2 séances** et s'effectue en binôme. Vous présenterez votre analyse lors d'un cours oral de 15 minutes.

1 Données

Les données sont disponibles sur Moodle. La description fournie reprend l'annexe B1 de l'article Ding, Frances, et al. "Retiring adult : New datasets for fair machine learning." Advances in neural information processing systems 34 (NeurIPS 2021) : 6478-6490.

1.1 Découverte des données

A partir de la documentation, quelles sont les informations disponibles dans le jeu de données *ACSIncome* ?

1.2 Echauffement en pandas

Pour importer et inspecter ces données, nous utiliserons la librairie Python Pandas. Nous recommendons les notebooks Jupyter pour l'implémentation.

```
import pandas as pd
df = pd.read_csv('Dataset/Data/California/acsincome_ca_features.csv')
df.head() #to visualize the first 5 lines
```

Le tableau de données est représenté par un objet DataFrame. On peut extraire des données selon des critères donnés, similairement aux requêtes SQL. Un bref tutoriel utile : `https://pandas.pydata.org/docs/getting_started/intro_tutorials/03_subset_data.html#min-tut-03-subset`

- Combien y-a-t-il d'individus californiens ?
- Parmi eux, combien ont plus de 30 ans ?
- Afficher les premiers individus de plus de 30 ans qui sont mariés.

2 Analyse

1. Formuler une problématique associée à ces données. Proposer ensuite une analyse pour y répondre.

   Pour supporter votre analyse, vous produirez au moins cinq graphiques commentés. Veillez à varier le type de graphique (histogramme, barre, nuage de points, ...). A titre d'exemple, voici 4 rapports d'analyse sur des données différentes : `https://homepages.laas.fr/gtredan/tmds/rapports1-4.pdf`.

Rendu. Vous déposerez sur Moodle un pdf de 5 pages maximum avec vos graphiques commentés, ainsi que le script python les ayant produit.

3 Pré-traitement

2 Dans le TP 2, nous entraînerons des modèles à prédire si un individu a un revenu supérieur à 50 000 USD. A l'aide de votre analyse, proposer un pré-traitement des données de Californie. Effectueriez-vous le même sur les données du Colarado ou du Nebraska ?

Rendu. A l'aide de graphiques, vous décrirez et justifierez les traitements effectués.

3 Enfin, proposer une partition des données. Qu'est-ce que votre jeu de test permettra d'évaluer ?